

Báo cáo Project-Based Learning

Fine-tuning Mô hình Stylist Đa phương thức
cho Hệ thống Gợi ý Trang phục

Môn học: Deep Learning • Năm học 2025–2026

Nguyễn Nhật Quang

Sinh viên năm 3 — Ngành Trí tuệ Nhân tạo
Trường CNTT&TT — Đại học FPT

Giảng viên hướng dẫn: *[Tên GV]*

Tháng 07 năm 2026

Abstract

Báo cáo này trình bày quá trình xây dựng và tinh chỉnh mô hình *Stylist* — thành phần giao tiếp bằng ngôn ngữ tự nhiên trong hệ thống gợi ý trang phục OutfitMatch. Trọng tâm của đề án là áp dụng các kỹ thuật học sâu hiện đại: học chuyển giao qua mô hình ngôn ngữ lớn (LLM) tiền huấn luyện, tinh chỉnh tham số thấp (LoRA/QLoRA), lượng tử hóa 4-bit, và học tăng cường với phần thưởng có thể kiểm chứng (GRPO). Chúng tôi so sánh bốn ứng viên dựa trên Qwen3-VL-8B, Qwen3.5-9B và Gemma-4-12B, huấn luyện trên **11.252 mẫu hội thoại tiếng Việt**, và chọn Qwen3-VL-8B-Thinking + LoRA (4-bit) làm mô hình sản xuất với Tool-F1 đạt **0.8980**, tỷ lệ tuân thủ định dạng **1.0** và eval loss **0.5943**.

Từ khóa: LoRA · QLoRA · GRPO · Tool-calling · Qwen3-VL · Lượng tử hóa 4-bit · Verifiable Reward

Contents

1	Giới thiệu	2
1.1	Bối cảnh và động lực	2
1.2	Vấn đề nghiên cứu	2
2	Cơ sở lý thuyết	2
2.1	Mô hình ngôn ngữ lớn và học chuyển giao	2
2.2	LoRA và QLoRA — Tinh chỉnh tham số thấp	3
2.3	Học tăng cường với phần thưởng có thể kiểm chứng (GRPO)	3
3	Phương pháp	3
3.1	Lựa chọn mô hình nền tảng	3
3.2	Công cụ truy vấn (Tool-calling schema)	4
3.3	Tập dữ liệu huấn luyện	4
3.4	Cấu hình huấn luyện (SFT — QLoRA)	5
4	Thực nghiệm và Kết quả	6
4.1	Thiết lập đánh giá	6
4.2	Kết quả so sánh bốn adapter (SFT)	6
4.3	Học tăng cường (GRPO) — thử nghiệm và giới hạn	6
4.4	Kết quả baseline GRPO trên GPU thật	7
5	Thảo luận	8
5.1	Bài học về đo lường chất lượng mô hình	8
5.2	Trade-off đa phương thức vs. nguồn ngữ	8
5.3	Hạn chế	8
6	Kết luận	8

1 Giới thiệu

1.1 Bối cảnh và động lực

OutfitMatch là hệ thống gợi ý trang phục nhận thức dáng người và dịp mặc (*Body & Occasion-Aware Fashion Recommender*), phát triển trong khuôn khổ môn học Deep Learning. Hệ thống hoạt động theo kiến trúc 4 tầng (hình 1): (1) Knowledge Base (KB), (2) Stylist, (3) Retrieval, và (4) Personalization (Quiz). Trong đó, tầng Stylist đóng vai trò *giao diện hội thoại*: tiếp nhận yêu cầu tiếng Việt (văn bản và/hoặc ảnh) từ người dùng, diễn giải ý định (*intent parsing*), quyết định gọi công cụ (*tool-calling*) để truy vấn kho outfit, và cuối cùng giải thích kết quả bằng tiếng Việt mà không bịa thông tin.




Figure 1. Vị trí tầng Stylist trong kiến trúc OutfitMatch v3.1-lite (4 tầng).

1.2 Vấn đề nghiên cứu

Việc dùng một LLM chung (off-the-shelf) làm stylist gặp ba thách thức đặc thù:

- **Ánh xạ ngôn ngữ tự nhiên sang từ vựng kiểm soát (*controlled vocabulary*):** người dùng viết “đi làm”, “đi tiệc cưới”, “tránh màu sáng” nhưng hệ thống retrieval chỉ chấp nhận các giá trị enum tiếng Anh `snake_case` (ví dụ `office`, `wedding`, `elegant`).
- **Chống ảo giác (*anti-hallucination*):** mô hình không được tự bịa `outfit_id` hay giá tiền không tồn tại trong KB.
- **Đa phương thức (*multimodal*):** hỗ trợ người dùng gửi ảnh selfie/ảnh outfit để phân tích dáng người.

Báo cáo này tập trung vào việc giải quyết các vấn đề trên bằng phương pháp *fine-tuning* một LLM đa phương thức nền tảng, thay vì xây dựng mô hình từ đầu (vốn không khả thi về dữ liệu và compute).

2 Cơ sở lý thuyết

2.1 Mô hình ngôn ngữ lớn và học chuyển giao

Mô hình Stylist được xây dựng trên kiến trúc Transformer decoder-only tiền huấn luyện trên quy mô lớn. Thay vì huấn luyện từ đầu, chúng tôi tận dụng *transfer learning*: trọng số tiền huấn luyện mang năng lực ngôn ngữ đa ngôn ngữ và suy luận chung, sau đó được tinh chỉnh trên tập

dữ liệu hội thoại thời trang tiếng Việt. Với biến thể đa phương thức Qwen3-VL, mô hình bổ sung một bộ mã hóa thị giác (ViT — *Vision Transformer*) nối vào backbone LLM qua cơ chế chiếu chéo (cross-attention projection). Đầu vào có thể là văn bản, ảnh, hoặc cả hai trong cùng một prompt.

2.2 LoRA và QLoRA — Tinh chỉnh tham số thấp

Huấn luyện toàn bộ (> 8 tỷ tham số) đòi hỏi VRAM vượt quá giới hạn phần cứng (GPU 8–16 GB). Chúng tôi dùng **QLoRA** (Quantized LoRA) [1], kết hợp:

- **Lượng tử hóa 4-bit NF4 + double-quant** giảm bộ nhớ trọng số nền tảng từ ~ 16 GB (bf16) xuống ~ 4 –5 GB.
- **LoRA** [2]: chỉ huấn luyện các ma trận hệ số thấp $\Delta W = BA$ (rank $r = 16$, $\alpha = 32$) ghép vào các projection layers, đồng bằng trọng số gốc.

Số tham số huấn luyện chỉ chiếm một phần nhỏ của toàn bộ mô hình, giúp quá trình huấn luyện chạy trên GPU T4 (Kaggle) và RTX 5060 Laptop 8 GB (máy dev).

2.3 Học tăng cường với phần thưởng có thể kiểm chứng (GRPO)

Sau SFT (Supervised Fine-Tuning), chúng tôi thử nghiệm **GRPO** (Group Relative Policy Optimization) [3] — thuật toán RL on-policy không dùng Reward Model. GRPO sinh G hoàn chỉnh cho mỗi prompt, chuẩn hóa phần thưởng theo trung bình và độ lệch chuẩn của nhóm, và tối ưu bằng PPO-style clipped objective kèm KL penalty ($\beta = 0.04$):

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}, \quad (1)$$

$$\mathcal{L}_{\text{GRPO}} = -\mathbb{E} \left[\min \left(\frac{\pi_\theta(y_i | x)}{\pi_{\text{old}}(y_i | x)} \hat{A}_i, \text{clip} \left(\frac{\pi_\theta}{\pi_{\text{old}}}, 1 - \epsilon, 1 + \epsilon \right) \hat{A}_i \right) - \beta \text{KL}(\pi_\theta \| \pi_{\text{ref}}) \right]. \quad (2)$$

Phần thưởng r_i ở đây là các hàm quy tắc xác định (*deterministic scorers*) trên tri thức thời trang, không cần mô hình phân xét — đảm bảo *verifiable reward*.

3 Phương pháp

3.1 Lựa chọn mô hình nền tảng

Chúng tôi khảo sát ba ứng viên (bảng 1). Tiêu chí then chốt: hỗ trợ tiếng Việt, có công cụ gọi hàm (*native tool-calling*), và VRAM 4-bit thấp.

Table 1. Ba ứng viên mô hình nền tảng cho tầng Stylist.

Thuộc tính	Qwen3.5-9B	Qwen3-VL-8B	Gemma-4-12B
Kiến trúc	Decoder-only	ViT + LLM (VL)	Decoder-only
Tham số	9B	8B (LLM 7.5B + ViT 0.5B)	12B
Modal đầu vào	Chỉ văn bản	Văn bản + Ảnh	Chỉ văn bản
Tool-calling	Có	Có	Không (prompt hack)
VRAM (4-bit)	~ 5 –6 GB	~ 4 –5 GB	~ 7 –8 GB
Tiếng Việt	Tốt	Khá	Yếu

Quyết định thiết kế: chọn **Qwen3-VL-8B** làm mô hình chính vì khả năng đa phương thức (chấp nhận ảnh người dùng — tính năng cốt lõi v3.1) và tool-calling native; Qwen3.5-9B làm phương án fallback text-only; Gemma-4-12B chỉ để so sánh ablation.

3.2 Công cụ truy vấn (Tool-calling schema)

Mô hình không truy xuất trực tiếp mà gọi công cụ `search_outfits` với các tham số có kiểu enum lấy từ `vocab.py` — nguồn duy nhất của controlled vocabulary:

Listing 1. Định nghĩa công cụ `search_outfits` (trích xuất từ `tools.py`).

```
SEARCH_OUTFITS_TOOL = {
    "name": "search_outfits",
    "parameters": {
        "occasion": enum(list(OCCASION)),      # bat buoc
        "style": enum(list(STYLE)),
        "body_shape": enum(list(BODY_SHAPE)),
        "skin_tone": enum(list(SKIN_TONE)),
        "price_max": integer,                  # VND
        "exclude_colors": array[string],
    },
    "required": ["occasion"],
}
```

Định dạng wire-format chuẩn hóa: `<tool_call>{"name":"search_outfits","arguments":{...}}</tool_call>`. Một lớp *validation* kiểm tra mọi `outfit_id` sinh ra có tồn tại trong KB và mọi tham số tool có hợp lệ theo schema — cơ chế chống ảo giác cứng (*hard guardrail*).

3.3 Tập dữ liệu huấn luyện

Tập dữ liệu cuối (*final merged dataset*) gồm **11.252 mẫu huấn luyện / 348 mẫu eval**, trong đó 1.360 mẫu huấn luyện và 40 mẫu eval là các cặp tool-calling. Dữ liệu kết hợp ba nhóm hành vi: `tool_calling` / `tool_calling_grounded` (học gọi đúng field/enum); `recommend_explain` (giải thích outfit); `ask_missing_info` (hỏi lại khi thiếu thông tin); `polite_decline`, `anti_hallucination` (từ chối khi thiếu dữ kiện); `body_fit`, `multi_turn`, `stylist_knowledge` (tư vấn đáng, hội thoại đa lượt, kiến thức phối đồ). Dữ liệu sinh tổng hợp (*synthetic*) bằng Gemini Flash cộng metadata catalog Việt Nam, chuẩn hóa sang định dạng ChatML.

Các hình 2–5 minh họa phân bố và chất lượng tập dữ liệu sau công chất lượng (*quality gate*) chưng lọc (*distillation*).




Figure 2. Phân bố chủ đề hội thoại: raw (trước quality gate) vs. distilled (sau lọc).




Figure 3. Phong cách prompt raw vs. distilled — các mẫu phức tạp được loại.




Figure 4. Số mẫu bị loại qua từng tầng quality gate.




Figure 5. Histogram độ dài câu trả lời: raw vs. distilled.




Figure 6. Phân nhóm kích thước gia đình outfit raw vs. distilled.

3.4 Cấu hình huấn luyện (SFT — QLoRA)

Pipeline dùng **Unsloth** trên Kaggle T4×2. Cấu hình chính (bảng 2):

Table 2. Hyperparameters huấn luyện QLoRA (theo stylist_finetune_kaggle.yaml).

Tham số	Giá trị
Framework	Unsloth + QLoRA (SFT)
Quantization	4-bit NF4, double-quant
LoRA rank r / α	16 / 32
LoRA dropout / bias	0.05 / none
Target modules	q,k,v,o_proj; gate,up,down_proj
Max seq length	2048
Batch (per device)	1 (effective = $1 \times \text{GPU} \times 8$ grad-accum)
Learning rate	2×10^{-4} (cosine, warmup 3%)
Epochs	1 (704 steps)
Optimizer	AdamW 8-bit (paged)

Lưu ý kỹ thuật: `device_map={"":0}` (không dùng "auto" gây lỗi CPU-dispatch), và `torch_dtype="auto"` (tránh lỗi dtype của lm_head với checkpoint bnb-4bit đồng bằng).

Hình 7 cho thấy giao diện theo dõi huấn luyện trên LLaMA-Factory, ghi nhận qua 704 steps (1 epoch) trên dataset 11.252 mẫu.



Figure 7. Giao diện LLaMA-Factory theo dõi fine-tune QLoRA trên Kaggle T4 (704 steps, 1 epoch).

4 Thực nghiệm và Kết quả

4.1 Thiết lập đánh giá

Chúng tôi dùng 70 *held-out prompts* phủ các loại tác vụ. Các metric: `mean_tool_call_f1` (F1 trên field/value tool-call — quan trọng nhất vì ảnh hưởng trực tiếp đến retrieval E2E); `mean_text_similarity`; `format_compliance_rate`; `error_count`.

4.2 Kết quả so sánh bốn adapter (SFT)

Bốn adapter được huấn luyện trên cùng dataset, cùng benchmark (bảng 3).

Table 3. Kết quả benchmark 4 adapter QLoRA (nguồn: `stylist_final_qlora_benchmark`).

Model	Eval loss	Tool F1	Text sim	Format
T3 Qwen3-VL-8B Thinking	0.5943	0.8980	0.5519	1.0000
T2 Qwen3.5-9B BNB4	0.6880	0.8776	0.4877	1.0000
T1 Qwen3-VL-8B Instruct	0.6027	0.8571	0.5437	1.0000
T4 Gemma-4-12B IT	0.6255	0.6531	0.5354	0.9714

Phân tích. T3 thắng tổng thể vì ổn định nhất: eval loss thấp nhất, Tool F1 cao nhất, text similarity cao nhất và compliance 1.0. Đáng chú ý, **eval loss không quyết định ranking** — Gemma có loss 0.6255 nhưng Tool F1 chỉ 0.6531 vì không “học” trigger gọi tool (đạt 0.0000 ở nhóm `tool_calling non-grounded`). Với bài toán có *contract cứng*, chất lượng phải đo bằng hành vi tool-calling chứ không chỉ likelihood.

4.3 Học tăng cường (GRPO) — thử nghiệm và giới hạn


Chúng tôi thiết kế 6 hàm phần thưởng xác định (bảng 4) cầu nối từ `fashion_eval.py` sang GRPOTrainer của TRL.

Table 4. 6 reward functions cho GRPO (nguồn: grpo_rewards.py).

Mã	Scorer	Đo lường
R1	occasion_formality	Precision/recall/F1 trên enum formality
R2	body_shape_advice	Recall positive – 0.5×negative keywords
R3	season_advice	Recall positive – 0.5×negative keywords
R4	coherence	Binary accuracy (phù hợp/không)
R5	ask_back	1.0 nếu hỏi lại & không ảo giác
R6	tool_call_derivation	Tool-call F1 × enum_valid

Chạy thực tế trên RTX 5060 Laptop 8 GB cho thấy *giới hạn phần cứng*: ở `max_completion_length=96` (đủ RAM) câu trả lời bị cắt ngắn → `reward = 0`; ở `≥ 160` thì OOM. Tương tự trên Kaggle T4 16 GB, cấu hình fit duy nhất là `batch=1`, `G=2`, `max_completion_length=128`, và `reward vẫn = 0` do truncation. Fix thông qua *tightening prompt* (câu < 100 token, chỉ keyword/enum) đưa `reward` từ 0 lên 0.059 trên mô hình mock. Bài học then chốt: **GRPO cho 8B QLoRA không khả thi trên 8 GB VRAM** — cần T4×2 hoặc DeepSpeed. Đây là ranh giới thực tế giữa lý thuyết RL và ràng buộc phần cứng.

Hình 8 và 9 ghi nhận dữ liệu W&B thật từ run GRPO (6sk8ezb1, project vominnhhatquang-fpt-univer) **train/reward = 0 ở mọi step** (global_step 10–60), run ghi nhận là *crashed*. Đây là bằng chứng thật của giới hạn, **không** phải kết quả thành công.

**Figure 8.** W&B: train/reward qua 6 steps của run GRPO 6sk8ezb1 — `reward = 0` ở mọi step do truncation (giới hạn 8 GB VRAM).**Figure 9.** W&B: bảng metric thật của run 6sk8ezb1 — `reward/loss = 0`, run *crashed*. Bằng chứng giới hạn, không phải thành công.

4.4 Kết quả baseline GRPO trên GPU thật

Benchmark rule-based trên 28 items × 6 scorers (bảng 5):

Table 5. Mean score các scorer trên GPU RTX 5060 8 GB (rev 3, đã fix vocabulary bug).

Task	T1 (VL Instruct)	T2 (9B text)	T3 (VL Thinking)
occasion_formality	0.607	0.585	0.740
body_shape_advice	0.000	0.050	0.040
season_advice	0.258	0.333	0.383
coherence	0.500	1.000	0.500
ask_back	0.667	0.667	0.667
tool_call_derivation	0.812	0.788	0.763
Overall mean	0.462	0.543	0.524

T3 dẫn đầu ở kiến thức dịp/mùa và có tool-calling SFT mạnh nhất, là mục tiêu RL dù mean thấp hơn T2 một chút vì là mô hình đa phương thức duy nhất (có vision tower).

5 Thảo luận

5.1 Bài học về đo lường chất lượng mô hình

Với hệ thống có *tool contract cứng*, eval loss là metric gây hiểu lầm: một mô hình có loss thấp vẫn có thể sai enum, bỏ quên `<tool_call>`, hay trả lời prose thay vì JSON. Benchmark hành vi (Tool F1, format compliance) phải là tiêu chí chọn mô hình chính.

5.2 Trade-off đa phương thức vs. nguồn ngữ

Qwen3-VL-8B (Thinking) thắng dự Qwen3.5-9B text-only vì tính năng ảnh người dùng là yêu cầu cốt lõi, và vision tower không thể thêm sau vào mô hình text-only. Đây là ví dụ ưu tiên *fit với bài toán sản phẩm* hơn tối ưu benchmark hẹp.

5.3 Hạn chế

Benchmark 70 mẫu chưa đủ sâu cho regression; GRPO chưa chạy thành công trên compute hiện có do giới hạn độ dài sinh; dữ liệu tool-calling hard-case còn mỏng.

6 Kết luận

Đồ án hiện thực hóa thành công tăng Stylist của OutfitMatch bằng fine-tuning LLM đa phương thức — minh họa chu trình: transfer learning → QLoRA → tool-calling schema → verifiable-reward RL → benchmark hành vi. Kết quả: (1) fine-tune thành công 4 adapter QLoRA trên Kaggle, publish lên Hugging Face; (2) chọn **Qwen3-VL-8B-Thinking + LoRA (4-bit)**: Tool F1 = 0.8980, Format = 1.0, Eval loss = 0.5943; (3) thiết kế 6 deterministic reward functions cho GRPO và phát hiện giới hạn phần cứng thực tế của RL 8B trên GPU 8 GB. Hướng phát triển: tăng dữ liệu hard-case, mở rộng benchmark lên 200–500 mẫu, thêm constrained decoding / parser repair, và chạy GRPO trên T4×2.

Lời cảm ơn

Đồ án sử dụng tài nguyên Kaggle T4 và RTX 5060 8 GB. Cảm ơn nhóm OutfitMatch (3 thành viên) và giảng viên.

References

- [1] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer. *QLoRA: Efficient Finetuning of Quantized LLMs*. arXiv:2305.14314, 2023.
- [2] E. J. Hu, Y. Shen, P. Wallis, et al. *LoRA: Low-Rank Adaptation of Large Language Models*. arXiv:2106.09685, 2021.
- [3] Z. Shao, P. Wang, Q. Zhu, et al. *DeepSeekMath*. arXiv:2402.03300, 2024.
- [4] Z. Liu, et al. *Dr. GRPO*. arXiv:2503.20783, 2025.
- [5] M. Vasileva, et al. *Learning Type-Aware Embeddings for Fashion Compatibility*. ECCV 2018.
- [6] Qwen Team. *Qwen3-VL Technical Report*. <https://github.com/QwenLM/Qwen3-VL>, 2025.